Spark 集群部署

搭建 Spark 平台是开发 Spark 应用程序的第一步,也是至关重要的一步。针对不同的应用场景,Spark 集群的运行模式有多种,本章将详细介绍 Standalone模式下 Spark 集群的部署。

1.运行环境说明

1.1 环境要求

- 已成功安装并运行 VMWare,并至少创建了两个虚拟机节点。
- 己在创建出的虚拟机上成功部署 Hadoop2.7.3

1.2 软件说明

■ scala-2.11.11.tgz

Scala (Java Development Kit)是开发工具包。Spark 是基于 Scala 开发的,Spark 集群的部署需要预先安装 Scala。

可根据集群实际情况在 Scala 官网下载所需安装版本:

https://www.scala-lang.org/download/all.html

spark-2.2.0-bin-hadoop2.7.tgz

Spark2.2.0 安装包。

可到 Spark 官网下载所需安装版本:

http://spark.apache.org/downloads.html

2 安装 Scala

第1步. 下载并解压 scala 压缩包。

将 scala 安装包移至 hduser 用户的主目录(/home/hduser)下,然后解压。

\$ tar -zvxf scala-2.11.11.tgz

第2步. 配置系统文件。

\$ sudo gedit /etc/profile

在打开的/etc/profile 文件中配置以下环境变量:

export SCALA_HOME=/home/hduser/scala-2.11.11 export PATH=\$PATH:\$SCALA_HOME/bin

第3步, 使配置生效。

\$ source /etc/profile

第4步. 将从 scala 安装包解压出文件夹的发送至 node02、node03。

\$ scp -r ~/scala-2.11.11 node02:~/ \$ scp -r ~/scala-2.11.11 node03:~/

分别在 node02、node03 上重复步骤 2 和步骤 3。

第5步.验证。

分别在 node01、node02、node03 执行下述语句验证,如果安装成功会显示如图 2.1-2.3 中所示的版本信息。

\$ scala -version

图 2.1 node01 节点 Scala 安装示意图

图 2.2 node02 节点 Scala 安装示意图

3 安装 Spark

3.1 下载并解压 Spark 安装包

在 Apache 官网下载相应版本的 Spark,然后移至 node01 节点 hduser 用户主目录(/home/hduser)下并对其解压。

```
$ tar -zvxf spark-2.2.0-bin-hadoop2.7.tgz
```

执行该命令后会在 hduser 的主目录下生成 spark-2.2.0-bin-hadoop2.7 文件夹, 为方便后续操作,将其重命名为 spark-2.2.0。

```
$ mv spark-2.2.0-bin-hadoop2.7 spark-2.2.0
```

Spark 相关配置文件均放在 spark-2.2.0/conf 中,如下图所示。

```
hduser@node01:~/spark-2.2.0/conf
hduser@node01:~/spark-2.2.0$ cd conf
hduser@node01:~/spark-2.2.0/conf$ ll
total 40
          2 hduser hduser 4096 Jun 30 16:09
drwxr-xr-x
drwxr-xr-x 12 hduser
                    hduser 4096 Jun 30 16:09
             hduser hduser 996 Jun 30 16:09 docker.properties.template
             hduser hduser 1105 Jun 30 16:09 fairscheduler.xml.template
             hduser hduser 2025 Jun 30 16:09 log4j.properties.template
             hduser hduser 7313 Jun 30 16:09 metrics.properties.template
             hduser hduser
                            865 Jun
                                    30
                                       16:09 slaves.template
             hduser hduser 1292 Jun 30 16:09 spark-defaults.conf.template
          1 hduser hduser 3699 Jun 30 16:09 spark-env.sh.template*
hduser@node01:~/spark-2.2.0/conf$
```

图 3.1 spark-2.2.0/conf 目录示意图

3.2 配置 spark-env.sh

第 1 步. 进入 spark-2.2.0/conf,复制其中的 spark-env.sh.template 并另存为该目录下的 spark-env.sh。

```
$ cd spark-2.2.0/conf
$ cp spark-env.sh.template spark-env.sh
```

第2步. 打开 spark-env.sh。

\$ gedit spark-env.sh

第3步. 将以下代码添加至 spark-env.sh 中。

export HADOOP HOME=/home/hduser/hadoop-2.7.3

```
export HADOOP_CONF_DIR=/home/hduser/hadoop-2.7.3/etc/hadoop/
export JAVA_HOME=/home/hduser/jdk1.8.0_151
export SCALA_HOME=/home/hduser/scala-2.11.11
export SPARK_MASTER_IP=192.168.146.140
export SPARK_MASTER_PORT=7077
export SPARK_MASTER_WEBUI_PORT=8080
export SPARK_WORKER_PORT=7078
export SPARK_WORKER_PORT=8081
export SPARK_WORKER_CORES=1
export SPARK_WORKER_INSTANCES=1
export SPARK_WORKER_MEMORY=2g
```

其中参数 HADOOP_CONF_DIR、JAVA_HOME、SCALA_HOME、SPARK_MASTER_IP 需要用户根据实际安装情况进行配置。

- SPARK_MASTER_IP: Spark 集群中 Master 节点的 IP 地址(本例令 node01 作为 Master)。
- SPARK MASTER PORT: Master 的启动端口(默认: 7077)。
- SPARK MASTER WEBUI PORT: Master 的 Web UI 端口(默认: 8080)。
- SPARK_WORKER_PORT: Worker 的启动端口(默认: 7078)。
- SPARK_WORKER_CORES: 每台 Worker 可用的 CPU 内核数量 (默认: 所有可用)。
- SPARK_WORKER_MEMORY: 每台 Worker 可使用的内存容量(默认: 所有 RAM 去掉操作系统所用的 1 GB)。需要注意,该参数值必须是整数值,单位只能是 g 或 m,例如 2g 或者 1000m。
- SPARK WORKER WEBUI PORT: Worker的 Web UI端口(默认:8081)。

3.3 配置 spark-defaults.conf

第 1 步. 进入 spark-2.2.0/conf,复制 spark-defaults.conf.template 并另存为该目录下的 spark-defaults.conf。

\$ cd spark-2.2.0/conf

\$ cp spark-defaults.conf.template spark-defaults.conf

第2步. 打开 spark-defaults.conf。

\$ gedit spark-defaults.conf

第3步. 向 spark-defaults.conf 添加以下代码:

spark.master=spark://<mark>192.168.146.140</mark>:7077

该参数需要根据用户 Master 节点实际 IP 地址进行配置。

3.4 配置 slaves

第 1 步. 进入 spark-2.2.0/conf,复制其中的 slaves.template 并另存为该目录下的 slaves。

\$ cp slaves.template slaves

第2步. 打开 slaves。

\$ gedit slaves

第3步. 在 slaves 中添加 Spark 中 Worker 节点的机器名或 IP 地址。

192.168.146.138

192.168.146.139

需要注意,在编辑 slaves 文件时每个机器名或 IP 地址独占一行。

3.5 配置环境变量

第1步. 配置系统文件。

\$ cd

\$ sudo gedit /etc/profile

在打开的/etc/profile 文件中配置以下环境变量:

export SPARK_HOME=/home/hduser/spark-2.2.0

export PATH=\$PATH:\$SPARK_HOME/bin

第2步. 使配置生效。

\$ source /etc/profile

3.6 配置 node02、node03

将 node01 上配置完成的 spark-2.2.0 文件夹发送至 node02、node03.

\$ scp -r ~/spark-2.2.0 node02:~/

\$ scp -r ~/spark-2.2.0 node03:~/

分别在每个节点上重复3.5节中步骤。

3.7 启动 Spark

在 node01 节点执行以下步骤:

第1步. 启动 Hadoop。

```
$ cd ~/hadoop-2.7.3
$ sbin/start-all.sh
```

第2步. 进入 spark-2.2.0 启动集群。

```
$ cd
$ cd spark-2.2.0
$ sbin/start-all.sh
```

第 3 步. 验证集群是否搭建成功,分别在 node01、node02、node03 上通过 jps 命令查看进程,如下图 3.2-3.4 所示。

```
hduser@node01:~/spark-2.2.0$ sbin/start-all.sh starting org.apache.spark.deploy.master.Master, logging to /home/hduser/spark-2.2.0/logs/spark-hduser-org.apache.spark.deploy.master.Master-1-node01.out 192.168.146.131: starting org.apache.spark.deploy.worker.Worker, logging to /home/hduser/spark-2.2.0/logs/spark-hduser-org.apache.spark.deploy.worker.Worker-Uorker-1-node03.out 192.168.146.130: starting org.apache.spark.deploy.worker.Worker, logging to /home/hduser/spark-2.2.0/logs/spark-hduser-org.apache.spark.deploy.worker.Worker-1-node02.out hduser@node01:~/spark-2.2.0$ jps 3490 SecondaryNameNode 3634 ResourceManager 5701 Master 5767 Jps 3289 NameNode hduser@node01:~/spark-2.2.0$
```

图 3.2 node01 开启 Hadoop 与 Spark 后进程示意图

```
hduser@node02:~

hduser@node02:~$ jps

2882 DataNode

2967 NodeManager

4439 Worker

4524 Jps

hduser@node02:~$
```

图 3.3 node02 开启 Hadoop 与 Spark 后进程示意图

图 3.4 node03 开启 Hadoop 与 Spark 后进程示意图

也可通过 Spark-shell 进一步验证 Spark 集群的安装情况。进入 spark-2.2.0 执

行如下指令:

\$ bin/spark-shell

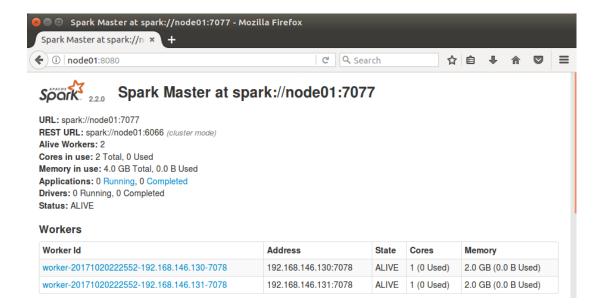
如果集群正常启动,Spark-shell 如图 3.5 所示。

```
Description in the distribution of the property of the proper
```

图 3.5 Spark-shell 交互窗口

按 Ctrl+C 可退出 Spark-shell

也可通过 WebUI 查看 Spark 集群中各节点状态,node01、node02、node03 分别如下图 3.6-3.8 所示,其中 node01 节点监控端口号 8080,node02 与 node03 为 8081。



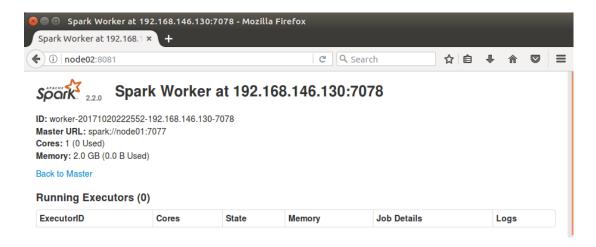


图 3.7 WebUI 监控 node02 节点状态



图 3.8 WebUI 监控 node03 节点状

至此,Standalone 部署模式的 Spark 集群搭建完成。